0 34.623660 78.024693 43.894998 1 30.286711 2 35.847409 72.902198 3 60.182599 86.308552 4 79.032736 75.344376 95 83.489163 48.380286 96 42.261701 87.103851 97 99.315009 68.775409 98 55.340018 64.931938 99 74.775893 89.529813 100 rows × 3 columns 2. Постройте график, где по осям откладываются оценки по предметам, а точки обозначаются двумя разными маркерами в зависимости от того, поступил ли данный студент в университет или нет. In [4]: | z true = df[df['accepted'] == 1] z false = df[df['accepted'] == 0] fig, ax = plt.subplots() ax.scatter(z\_true['first\_exam'], z\_true['second\_exam'], marker='o', c='g', label='Accepted', s=20) ax.scatter(z\_false['first\_exam'], z\_false['second\_exam'], marker='x', c='r', label='Not accepted', s ax.legend(loc='upper right'); ax.set\_xlabel('First exam') ax.set\_ylabel('Second exam') plt.show() 100 Not accepted 90 80 Second exam 70 50 40 30 First exam Реализация логистической регрессии в объекто-ориентированном стиле In [5]: **from utils import** sigmoid class LogisticRegression: THRESHOLD = 1e-6def \_\_init\_\_(self, fit\_method='gradient\_descent', max\_steps=100000, learning\_rate=0.01, regularized=False, reg\_L=0.5, log=False): self.weights = [] self.max\_steps = max\_steps self.learning\_rate = learning\_rate self.regularized = regularized self.reg\_L = reg\_L self.cost\_func = self.cost\_func\_regularized if regularized else self.cost\_func\_non\_regulariz self.cost\_der = self.cost\_der\_regularized if regularized else self.cost\_der\_non\_regularized self.fit\_method = getattr(self, fit\_method) self.log = logdef fit(self, X, y): if hasattr(X, 'values'): X = X.valuesif hasattr(y, 'values'): y = y.valuesX = X.astype('float64') y = y.astype('float64') if not self.regularized: X = np.column\_stack((np.ones(X.shape[0]), X)) self.fit\_method(X, y) def predict(self, X): if self.weights is None: raise Exception ("Model is not trained. Call `fit` method.") X = np.array(X)if not self.regularized: X = np.insert(X, 0, 1)h = self.calculate\_hypotesis(X) return 1 if  $h \ge 0.5$  else 0 def gradient\_descent(self, X, y): self.cost history = [] self.weights = np.zeros(X.shape[1]) cur loss = self.cost func(X, y) cur step = 0while cur\_step < self.max\_steps:</pre> cur step += 1 self.gradient descent\_step(X, y) new\_loss = self.cost\_func(X, y) self.cost\_history.append(new\_loss) if abs(new\_loss - cur\_loss) < self.THRESHOLD:</pre> cur\_loss = new\_loss def gradient\_descent\_step(self, X, y): gradient = self.cost der(X, y, self.weights) gradient \*= self.learning\_rate self.weights -= gradient def cost func non regularized(self, X, y, weights=None): if weights is None: weights = self.weights predictions = self.calculate hypotesis(X, weights) cost trues = y \* np.log(predictions)  $cost_falses = (1 - y) * np.log(1 - predictions)$ total cost = -np.mean(cost trues + cost falses) return total cost def cost\_func\_regularized(self, X, y, weights=None): if weights is None: weights = self.weights cost = self.cost func non regularized(X, y, weights) weights R = weights[1:] total\_cost = cost + (self.reg\_L / 2 / X.shape[0]) \* np.dot(weights\_R.T, weights\_R) return total cost def calculate hypotesis(self, X, weights=None): if weights is None: weights = self.weights return sigmoid(X.dot(weights)) def cost der non regularized(self, X, y, theta): predictions = self.calculate hypotesis(X, weights=theta) sq error = predictions - y gradient = np.dot(X.T, sq error) gradient /= X.shape[0] return gradient def cost der regularized(self, X, y, theta): predictions = self.calculate hypotesis(X, weights=theta) sq error = predictions - y gradient first = np.dot(X.T[:1], sq error) gradient\_full = np.dot(X.T[1:], sq\_error) + self.reg\_L \* theta[1:] gradient = np.insert(gradient full, 0, gradient first) gradient /= X.shape[0] return gradient def nelder mead algo(self, X, y): from scipy.optimize import fmin N = X.shape[0]def func(theta): return self.cost\_func(X, y, theta) init theta = np.zeros(X.shape[1]) self.weights = fmin(func, init theta, xtol=self.THRESHOLD, maxfun=100000) def bfgs algo(self, X, y): from scipy.optimize import fmin bfgs N = X.shape[0]def func(theta): return self.cost func(X, y, theta) def func der(theta): return self.cost der(X, y, theta) init theta = np.zeros(X.shape[1]) self.weights = fmin\_bfgs(func, init\_theta, fprime=func\_der, gtol=self.THRESHOLD, disp=self.l og) 3. Реализуйте функции потерь J(θ) и градиентного спуска для логистической регрессии с использованием векторизации. Функция потерь реализована в классе LogisticRegression в методе cost func non regularized. Градиентный спуск реализован в классе LogisticRegression в методах gradient descent и gradient descent step. In [6]: cls grad = LogisticRegression(fit method='gradient descent', max steps=300000, learning rate=0.004) cls grad.fit(X train, y train) print(f'Minimum cost function value: {cls\_grad.cost\_history[-1]}') print(f'Iterations: {len(cls grad.cost history)}') print(f'Weights: {cls grad.weights}') Minimum cost function value: 0.20379167132378806 Iterations: 264018 Weights: [-24.03770043 0.19769988 0.19281427] 4. Реализуйте другие методы (как минимум 2) оптимизации для реализованной функции стоимости. Выбранные методы: - Нелдера — Мида - Бройдена — Флетчера — Гольдфарба — Шанно In [7]: cls nm = LogisticRegression(fit method='nelder mead algo') cls nm.fit(X train, y train) print(f'Weights: {cls nm.weights}') Optimization terminated successfully. Current function value: 0.203498 Iterations: 185 Function evaluations: 339 Weights: [-25.16133398 0.20623172 0.2014716] In [8]: cls\_bfgs = LogisticRegression(fit\_method='bfgs\_algo', log=True) cls\_bfgs.fit(X\_train, y\_train) print(f'Weights: {cls\_bfgs.weights}') Optimization terminated successfully. Current function value: 0.203498 Iterations: 23 Function evaluations: 31 Gradient evaluations: 31 Weights: [-25.16133284 0.2062317 0.2014716] Как можно видеть из вывода, все методы минимазации функции стоимости дают приблизительно одинаковые результаты. 5. Реализуйте функцию предсказания вероятности поступления студента в зависимости от значений оценок по экзаменам. Функция предсказания реализована в классе LogisticRegression в методе predict. 6. Постройте разделяющую прямую, полученную в результате обучения модели. Совместите прямую с графиком из пункта 2. Из графика можно видеть, что граница решений разделяет два класс достаточно точно с минимальными ошибками. In [9]: z true = df[df['accepted'] == 1] z false = df[df['accepted'] == 0] def decision boundary(x, weights): return - (weights[0] + weights[1] \* x) / weights[2] fig, ax = plt.subplots() ax.scatter(z\_true['first\_exam'], z\_true['second\_exam'], marker='o', c='g', label='Accepted', s=20) ax.scatter(z\_false['first\_exam'], z\_false['second\_exam'], marker='x', c='r', label='Not accepted', s ax.plot(z false['first exam'], [decision\_boundary(i, cls\_grad.weights) for i in z\_false['first\_exam']], c='b', label='Decision boundary') ax.legend(loc='upper right'); ax.set xlabel('First exam') ax.set ylabel('Second exam') plt.show() 100 Decision boundary Accepted 90 Not accepted 80 Second exam 70 60 50 40 30 90 100 First exam 7. Загрузите данные ex2data2.txt из текстового файла. In [10]: df = load\_file('ex2data2.txt', names=['first\_test', 'second\_test', 'passed']) X\_train, y\_train = df.filter(['first\_test', 'second\_test']), df['passed'] Out[10]: first\_test second\_test passed 0 0.051267 0.699560 1 0.684940 1 -0.092742 0.692250 2 -0.213710 0.502190 3 -0.375000 4 -0.513250 0.465640 113 -0.720620 0.538740 114 -0.593890 0.494880 115 -0.484450 0.999270 116 -0.006336 0.999270 117 0.632650 -0.030612 118 rows × 3 columns 8. Постройте график, где по осям откладываются результаты тестов, а точки обозначаются двумя разными маркерами в зависимости от того, прошло ли изделие контроль или нет. In [11]: z true = df[df['passed'] == 1] z false = df[df['passed'] == 0] fig, ax reg = plt.subplots() ax\_reg.scatter(z\_true['first\_test'], z\_true['second\_test'], marker='o', c='g', label='Passed', s=20) ax\_reg.scatter(z\_false['first\_test'], z\_false['second\_test'], marker='x', c='r', label='Not passed', ax reg.legend(loc='upper right'); ax\_reg.set\_xlabel('First test') ax\_reg.set\_ylabel('Second test') plt.show() Passed 1.00 Not passed 0.75 0.50 Second test 0.25 0.00 -0.25-0.50-0.750.25 0.50 0.75 1.00 -0.75 -0.50 -0.25 0.00 9. Постройте все возможные комбинации признаков х1 (результат первого теста) и х2 (результат второго теста), в которых степень полинома не превышает 6 (всего 28 комбинаций). In [12]: def build\_poly\_features(x1, x2, log=False): degree = 6res = []str res = [] for i in range(degree + 1): for j in range(i, degree + 1): res.append(x1\*\*(j-i)\*x2\*\*i) first = '' if j - i == 0 else 'x1' if j - i == 1 else  $f'x1^{j} - i$ ' second = '' if i == 0 else 'x2' if i == 1 else  $f'x2^{i}$ ' if not first and not second: str append = '1' elif first and not second: str append = first elif second and not first: str append = second str append = f"{first}\*{second}" str\_res.append(str\_append) str res = ' + '.join(str res) if log: print(str res) assert len(res) == 28 return np.array(res).T In [13]: X\_poly = build\_poly\_features(X\_train['first\_test'], X\_train['second\_test'], log=True)  $1 + x1 + x1^2 + x1^3 + x1^4 + x1^5 + x1^6 + x^2 + x1^2 + x1^2 + x1^3 + x^2 + x1^4 + x^1 + x^2 + x^2$  $x^2 + x^1 + x^2 + x^1 + x^2 + x^1 + x^2 + x^1 + x^2 + x^2$  $^4 + x1*x2^4 + x1^2*x2^4 + x2^5 + x1*x2^5 + x2^6$ 10. Реализуйте L2-регуляризацию для логистической регрессии и обучите ее на расширенном наборе признаков методом градиентного спуска In [14]: cls grad reg = LogisticRegression(fit method='gradient descent', regularized=True, max steps=300000, learning rate=0.5, reg L=0.5) cls grad reg.fit(X poly, y train) print(f'Minimum cost function value: {cls grad reg.cost history[-1]}') print(f'Iterations: {len(cls grad reg.cost history)}') print(f'Weights: {cls\_grad\_reg.weights}') Minimum cost function value: 0.4830842899534604 Iterations: 810 Weights: [ 1.65208622 0.94431514 -2.64940137 0.25975329 -1.94720963 -0.28830575 -1.40795909 1.63711103 -1.41181861 -0.55414548 -0.06395618 -0.301303780.05023522 - 1.9845273 - 0.51557881 - 0.86765101 - 0.03547762 - 0.40798724-0.18554811 -0.44731424 -0.41074822 0.02884999 -1.60347872 -0.46001569-0.46740685 -0.52305424 -0.25283157 -1.18129922] 11. Реализуйте другие методы оптимизации. Используем ранее выбранные алгоритмы оптимизации In [15]: cls\_nm\_reg = LogisticRegression(fit\_method='nelder\_mead\_algo', regularized=True) cls nm reg.fit(X poly, y train) print(f'Weights: {cls\_nm\_reg.weights}') Optimization terminated successfully. Current function value: 0.555505 Iterations: 25954 Function evaluations: 31091 Weights: [ 1.12594906 0.24134085 -2.31420683 0.55470573 -1.67237848 -0.40342394 0.77128112 -1.50790055 -0.06941374 0.18185012 1.78287659 0.10760548 1.23201507 -1.16820284 -1.22854238 0.56241007 -0.94218806 0.97961079 -0.19487654 -0.73439587 1.2956786 -1.05680772] In [17]: cls\_bfgs\_reg = LogisticRegression(fit\_method='bfgs\_algo', regularized=True, log=True) cls bfgs reg.fit(X poly, y train) print(f'Weights: {cls\_bfgs\_reg.weights}') Optimization terminated successfully. Current function value: 0.482934 Iterations: 70 Function evaluations: 71 Gradient evaluations: 71 Weights: [ 1.69992017e+00 9.73425710e-01 -2.71205027e+00 2.69841288e-01 -1.97406880e+00 -3.01656781e-01 -1.42846670e+00 1.67267436e+00 -1.49381280e+00 -5.67645033e-01 -2.05207890e-02 -2.95925875e-01 8.26085884e-02 -2.11922466e+00 -5.01522975e-01 -8.94137108e-01 1.63371223e-03 -4.13878871e-01 -1.94825890e-01 -4.75526451e-01 -4.35533804e-01 5.34666739e-02 -1.62994970e+00 -4.80852527e-01 -4.86440776e-01 -4.74910329e-01 -2.77072656e-01 -1.13402788e+00] Как видим, результаты получились схожими для всех алгоритмов 12. Реализуйте функцию предсказания вероятности прохождения контроля изделием в зависимости от результатов тестов. Функция предсказания реализована в классе LogisticRegression в методе predict. In [19]: print(f"Predicted class: {cls\_grad\_reg.predict(X\_poly[0])}, actual class: {y\_train[0]}") print(f"Predicted class: {cls nm reg.predict(X poly[0])}, actual class: {y train[0]}") print(f"Predicted class: {cls\_bfgs\_reg.predict(X\_poly[0])}, actual class: {y\_train[0]}") Predicted class: 1, actual class: 1 Predicted class: 1, actual class: 1 Predicted class: 1, actual class: 1 13. Постройте разделяющую кривую, полученную в результате обучения модели. Совместите прямую с графиком из пункта 8. In [20]: **def** decision boundary contour(theta1, theta2, theta3): u = np.linspace(-1, 1.2, 50)v = np.linspace(-1, 1.3, 50)z1 = np.zeros(shape=(len(u), len(v)))z2 = np.zeros(shape=(len(u), len(v)))z3 = np.zeros(shape=(len(u), len(v)))for i in range(len(u)): for j in range(len(v)): z1[i, j] = build\_poly\_features(np.array(u[i]), np.array(v[j])).dot(theta1) z2[i, j] = build\_poly\_features(np.array(u[i]), np.array(v[j])).dot(theta2) z3[i, j] = build poly features(np.array(u[i]), np.array(v[j])).dot(theta3) z1 = z1.Tz2 = z2.Tz3 = z3.Tfig, ax\_reg = plt.subplots() ax\_reg.contour(u, v, z1, levels=0, colors='b') ax\_reg.contour(u, v, z2, levels=0, colors='g') ax reg.contour(u, v, z3, levels=0, colors='y') z\_true = df[df['passed'] == 1] z\_false = df[df['passed'] == 0] ax reg.scatter(z true['first test'], z true['second test'], marker='o', c='g', label='Passed', s ax\_reg.scatter(z\_false['first\_test'], z\_false['second\_test'], marker='x', c='r', label='Not pass ed', s=20) ax\_reg.legend(loc='upper right'); ax reg.set xlabel('First test') ax\_reg.set\_ylabel('Second test') ax reg.set title('Decision boundary, lambda = %f' % cls grad reg.reg L) plt.show() Проведём границу решений для всех трёх алгоритмов. Можно увидеть, что алгоритмы дают результаты, на основе которых можно построить приблизительно одинаковые границы с некоторой погрешностью. In [21]: decision\_boundary\_contour(cls\_grad\_reg.weights, cls\_nm\_reg.weights, cls\_bfgs\_reg.weights) Decision boundary, lambda = 0.500000 1.0 0.5 Second test 0.0 -0.5-1.00 -0.75 -0.50 -0.25 0.00 0.25 0.50 14. Попробуйте различные значения параметра регуляризации λ. Как выбор данного значения влияет на вид разделяющей кривой? Ответ дайте в виде графиков. In [24]: cls1 = LogisticRegression(fit method='gradient descent', max steps=300000, learning rate=0.5, regularized=True, reg L=0.5) cls1.fit(X\_poly, y\_train) cls2 = LogisticRegression(fit method='gradient descent', max steps=300000, learning rate=0.5, regularized=True, reg L=0.05) cls2.fit(X poly, y train) cls3 = LogisticRegression(fit\_method='gradient\_descent', max\_steps=300000, learning\_rate=0.5, regularized=True, reg L=0.005) cls3.fit(X\_poly, y\_train) In [25]: decision boundary contour(cls1.weights, cls2.weights, cls3.weights) Decision boundary, lambda = 0.500000 Passed Not passed 1.0 0.5 Second test -0.5-1.00 -0.75 -0.50 -0.25 0.50 0.75 1.00 0.00 0.25 Как видим из графика, изменение параметра регуляризации λ не производит сильного влияния на границу решений. 15. Загрузите данные ex2data3.mat из файла. In [26]: from scipy.io import loadmat mat = loadmat('ex2data3.mat') X train, y train = mat['X'], mat['y'] y\_train = y\_train.reshape(y\_train.shape[0]) y train = np.where(y train != 10, y train, 0) 16. Визуализируйте несколько случайных изображений из набора данных. Визуализация должна содержать каждую цифру как минимум один раз. In [27]: **def** vector to matrix(x): len vec = len(x)step = int(np.sqrt(len vec)) assert step \*\* 2 == len vec, 'Matrix should be squared' matrix = [x[left:left+step] for left in range(0, len vec, step)] np matrix = np.array(matrix).T reversed matrix = np.flip(np matrix, axis=0) return reversed matrix nums = list(range(150, 5000, 500)) pictures = [vector to matrix(X train[i]) for i in nums] fig, axs = plt.subplots(2, 5, figsize=(20, 8)) for i, ax in enumerate(axs.flatten()): ax.pcolor(pictures[i], cmap=cm.gray) res = y train[nums[i]] **if** res == 10: res = 0ax.set title(f'Number {res}') plt.show() Number 4 17.5 17.5 17.5 17.5 15.0 15.0 15.0 15.0 12.5 12.5 12.5 12.5 10.0 10.0 10.0 7.5 7.5 7.5 5.0 5.0 -5.0 2.5 2.5 2.5 0.0 -0.0 0.0 0.0 15 Number 6 Number 7 Number 8 Number 9 20.0 17.5 17.5 17.5 17.5 15.0 15.0 15.0 15.0 12.5 12.5 12.5 12.5 10.0 10.0 10.0 7.5 7.5 5.0 5.0 2.5 17. Реализуйте бинарный классификатор с помощью логистической регрессии с использованием векторизации (функции потерь и градиентного спуска). Бинарный классификатор с использованием векторизации реализован в классе LogisticRegression . Он содержит функцию потерь cost func non regularized, которая используется в методе градиентного спуска gradient\_descent. 18. Добавьте L2-регуляризацию к модели. Регуляризация добавляется к модели путём передачи в конструктор параметера regularized=True . В этом случае будет использовать использоваться функция стоимости cost func regularized . Градиент также будет высчитываться с учётом параметера регуляризации. 19. Реализуйте многоклассовую классификацию по методу "один против всех". Многоклассовая классификация реализована в классе MulticlassLogisticRegression . Обучается 10 бинарных классификаторов, по одному для каждого класса. In [28]: class MulticlassLogisticRegression: classifier = LogisticRegression def \_\_init\_\_(self, num\_classes=10): self.num\_classes = num\_classes self.classifiers = [ self.classifier(fit\_method='gradient\_descent', learning\_rate=0.5, regularized=True, reg\_ L=0.1)for i in range(num\_classes) def fit(self, X, y): for i in range(self.num\_classes): y\_train = (y == i).astype(int) self.classifiers[i].fit(X, y\_train) def predict(self, X): h = []for cls in self.classifiers: h.append(cls.calculate\_hypotesis(X)) return np.argmax(np.array(h), axis=0) 20. Реализуйте функцию предсказания класса по изображению с использованием обученных

классификаторов.

In [30]: pred\_value = cls\_mult.predict(X\_train[-1])

Predicted class: 9, actual class: 9

error = cls.predict(X) - y

In [32]: | acc = accuracy(cls\_mult, X\_train, y\_train)

print(f"Accuracy: {acc}")

классу.

In [31]: def accuracy(cls, X, y):

Accuracy: 0.9588

Функция предсказания реализована в классе MulticlassLogisticRegression в методе predict . Каждый из обученных классификаторов высчитывает гипотезу - вероятность того, что картинка принадлежит соответствующему

21. Процент правильных классификаций на обучающей

print(f"Predicted class: {pred\_value}, actual class: {y\_train[-1]}")

выборке должен составлять около 95%.

return 1.0 - (float(np.count\_nonzero(error)) / len(error))

Отчёт по лабораторной работе №2 "Логистическая

1. Загрузите данные ex2data1.txt из текстового файла.

регрессия"

import pandas as pd

import warnings

%matplotlib inline

In [2]: def load file(filename, names):

import matplotlib.pyplot as plt
import matplotlib.cm as cm

warnings.filterwarnings('ignore')

first exam second exam accepted

return pd.read csv(filename, header=None, names=names)

In [3]: | df = load file('ex2data1.txt', ['first exam', 'second exam', 'accepted'])

X train, y train = df.filter(['first exam', 'second exam']), df['accepted']

In [1]: import numpy as np

Out[3]: